



Wydział Matematyki i Nauk Informatycznych

POLITECHNIKA WARSZAWSKA

ANALIZA I PRZETWARZANIE DŹWIĘKU

PROJEKT 1

Cechy sygnału audio w dziedzinie czasu

Autorzy

Igor OLEKSY

Franciszek NIEDŹWIECKI

2 kwietnia 2026

Spis treści

1	Wstęp	3
2	Wczytywanie pliku audio i wizualizacja przebiegu czasowego	3
3	Parametry w dziedzinie czasu na poziomie ramki	4
3.1	Głośność	4
3.2	STE(Short Time Energy)	5
3.3	ZCR (Zero-Crossing Rate)	6
3.4	Częstotliwość tonu podstawowego F0 (Fundamental Frequency)	6
3.5	Eksperymenty związane z parametrami w dziedzinie czasu na poziomie ramki	7
3.5.1	Detekcja ciszy	7
3.5.2	Detekcja fragmentów dźwięcznych/bezdźwięcznych	7
3.5.3	Częstotliwość podstawowa	8
4	Parametry w dziedzinie czasu na poziomie klipu	11
4.1	VDR - Volume Dynamic Range	12
4.2	VSTD - Volume Standard Deviation	12
4.3	VU - Volume Undulation	12
4.4	LSTER - Low Short-Time Energy Ratio	12
4.5	Energy Entropy	13
4.6	HZCRR - High Zero-Crossing Rate Ratio	13
4.7	Eksperymenty związane z parametrami w dziedzinie czasu na poziomie klipu	13

1 Lista symboli i akronimów

Lista symboli matematycznych

- N - długość ramki w próbkach
- $s_n(i), S_n(i)$ - amplituda i -tej próbki w n -tej ramce
- $p(n)$ - głośność sygnału w ramce (pierwiastek średniej energii)
- $STE(n)$ - krótkookresowa energia sygnału (STE) w n -tej ramce
- $Z(n), ZCR(n)$ - liczba przejść amplitudy przez zero w n -tej ramce
- f_s - częstotliwość próbkowania sygnału audio
- $sgn(x), sign(x)$ - funkcja signum
- $R_n(l)$ - wartość funkcji autokorelacji dla n -tej ramki i opóźnienia l
- $A_n(l)$ - wartość funkcji AMDF dla n -tej ramki i opóźnienia l
- v - głośność w klipie audio (w kontekście wartości min i max)
- $avSTE$ - średnia wartość STE w 1-sekundowym oknie
- $avZCR$ - średnia wartość ZCR w 1-sekundowym oknie
- K - liczba próbek w segmencie
- J - całkowita liczba segmentów w klipie
- σ_i^2 - znormalizowana energia dla i -tego segmentu w klipie
- I - entropia energii wyliczona dla całego klipu

Lista akronimów

- AMDF - Średnia funkcja modułu różnicy (ang. *Average Magnitude Difference Function*)
- F0 - Częstotliwość tonu podstawowego (ang. *Fundamental Frequency*)
- HZCRR - ang. *High Zero Crossing Rate Ratio*
- LSTER - ang. *Low Short Time Energy Ratio*
- SR - ang. *Silent Ratio*
- STE - Krótkookresowa energia sygnału (ang. *Short Time Energy*)
- VDR - Dynamiczny zakres głośności (ang. *Volume Dynamic Range*)
- VSTD - Odchylenie standardowe głośności (ang. *Standard Deviation normalized by the maximum volume*)
- VU - Falistość głośności (ang. *Volume Undulation*)
- ZCR - Współczynnik przejść przez zero (ang. *Zero Crossing Rate*)
- ZSTD - Odchylenie standardowe współczynnika przejść przez zero (ang. *Standard Deviation of the ZCR*)

1 Wstęp

Celem projektu było zaimplementowanie aplikacji okienkowej służącej do ekstrakcji oraz analizy cech sygnału audio w dziedzinie czasu. Stworzona aplikacja umożliwia wczytywanie plików dźwiękowych w formacie .wav (wybór z okna dialogowego lub drag and drop). W ramach zadania zaimplementowano szereg narzędzi analitycznych działających na poziomie pojedynczej ramki sygnału, jak i globalnym poziomie klipu. Do głównych funkcjonalności programu należą:

- Wyznaczanie kluczowych parametrów w dziedzinie czasu (głośność, STE, ZCR)/
- Estymacja częstotliwości tonu podstawowego (F0) z wykorzystaniem dwóch niezależnych metod: funkcji autokorelacji oraz funkcji AMDF (Average Magnitude Difference Function)/
- Segmentacja sygnału, obejmująca detekcję ciszy, podział na fragmenty dźwięczne i bezdźwięczne, a także zaawansowaną klasyfikację mowa/muzyka/
- Eksport wyliczonych parametrów i wyników klasyfikacji do pliku z rozszerzeniem .txt, co umożliwia ich późniejszą analizę statystyczną.


Aplikacja została zaimplementowana w języku C#. Do interfejsu graficznego wykorzystano bibliotekę graficzną WinForms. Wykresy zostały wygenerowane z wykorzystaniem biblioteki ScottPlot, umożliwiającą dodatkowo interakcje z wykresem oraz zapisywanie do pliku.

2 Wczytywanie pliku audio i wizualizacja przebiegu czasowego

Pierwszym etapem projektu było wczytanie sygnału audio z pliku w formacie WAV oraz wizualizacja jego przebiegu czasowego. Pliki z rozszerzeniem .wav charakteryzują się strukturą, w której dane ułożone są w ściśle określonej kolejności. Prawidłowe odczytanie nagłówka jest procesem krytycznym, ponieważ definiuje sposób, w jaki program ma interpretować surowe próbki dźwiękowe. Standardowy plik WAV składa się z trzech głównych sekcji:

- **Blok główny RIFF:** Rozpoczyna się od identyfikatora „RIFF”, po którym następuje całkowity rozmiar pliku oraz identyfikator formatu. Potwierdza to, że mamy do czynienia z prawidłowym plikiem dźwiękowym.
- **Blok formatu:** Jest to najważniejsza sekcja z punktu widzenia analizy sygnału. Zawiera niezbędne parametry audio, takie jak:
 - **Format zapisu.**
 - **Liczba kanałów:** Informuje, czy sygnał jest monofoniczny, czy stereofoniczny.
 - **Częstotliwość próbkowania:** Wyrażona w hercach liczba próbek pobieranych w ciągu jednej sekundy
 - **Rozdzielczość bitowa :** Liczba bitów opisująca pojedynczą próbkę (w tym projekcie przyjęto obsługę plików 16-bitowych).
 - **Przepływność bajtowa oraz Wyrównanie bloku:** Parametry techniczne pozwalające na poprawne przesuwanie wskaźnika odczytu w strumieniu danych.
- **Blok danych:** Rozpoczyna się od nagłówka „data” i rozmiaru sekcji. Bezpośrednio po nich znajdują się właściwe, surowe próbki sygnału audio (wyrażone w bajtach), które w programie są konwertowane na wartości liczbowe (amplitudę).

Dzięki poprawnej ekstrakcji powyższych cech możliwe jest nie tylko poprawne zdekodowanie tablicy próbek, ale również wyliczenie osi czasu niezbędnej do narysowania przebiegu sygnału. Przykładowy przebieg czasowy audio dla zdania "Dlaczego ta zima nie może się już skończyć" zostało przedstawione na rysunku 1:



Rysunek 1: Przebieg czasowy audio dla przykładowego zdania

Plik ten będzie wykorzystany w późniejszych sekcjach w celu zobrazowania poprawności zaimplementowanych cech.

3 Parametry w dziedzinie czasu na poziomie ramki


Pierwszym etapem projektu było wyznaczenie podstawowych cech sygnału audio w dziedzinie czasu na poziomie ramki. Długość ramki ustalono na 0.01s.

3.1 Głośność

Pierwszą miarą była głośność. Obliczana ona jest ze wzoru:

$$p(n) = \sqrt{\frac{1}{N} \sum_{i=1}^N s_n^2(i)} \quad (1)$$

Powyższa miara charakteryzuje się wysoką skutecznością w zadaniu detekcji ciszy w sygnale audio. Znaczący spadek wartości głośności w danej ramce, zazwyczaj poniżej ustalonego progu, z bardzo dużym prawdopodobieństwem wskazuje na brak aktywnego sygnału. Pozwala to na precyzyjne wyodrębnienie przerw w mowie lub muzyce i oddzielenie ich od szumu tła. Rysunek 2 pokazuje wykres głośności dla przykładowego zdania.




Rysunek 2: Wykres głośności dla przykładowego zdania

3.2 STE(Short Time Energy)

Kolejnym ważnym parametrem na poziomie ramki jest wartość STE, która zdefiniowana jest jako podniesiona do kwadratu miara głośności:

$$STE(n) = \frac{1}{N} \sum_{i=1}^N s_n^2(i) \quad (2)$$

Wartość STE wykorzystuje się na przykład w detekcji dźwięcznych i bezdźwięcznych fragmentów mowy. Wartości STE dla dźwięcznych głosek są znacząco wyższe niż w przypadku bezdźwięcznych. Na rysunku 3 pokazano wykres dla naszego przykładowego zdania.




Rysunek 3: Wykres parametru STE dla przykładowego zdania

3.3 ZCR (Zero-Crossing Rate)

$$Z(n) = \frac{f_s}{2N} \sum_{i=1}^N |\text{sgn}(s_n(i)) - \text{sgn}(s_n(i-1))| \quad (3)$$

$$\text{sgn}(y) = \begin{cases} 1 & \text{dla } y > 0 \\ 0 & \text{dla } y = 0 \\ -1 & \text{dla } y < 0 \end{cases} \quad (4)$$

Wartość ZCR opisuje liczbę przejść amplitudy sygnału przez zero w jednej ramce. Miara ta jest również wykorzystywana do rozpoznania dźwięcznych i bezdźwięcznych fragmentów mowy. Zazwyczaj bezdźwięczna mowa posiada niską wartość energii, ale wysoką wartość ZCR. Z kolei wraz z głośnością, ZCR pozwala odróżniać bezdźwięczną mowę o niskiej energii od ciszy. Rysunek 4 pokazuje wykres parametru ZCR dla przykładowego zdania.



Rysunek 4: Wykres parametru ZCR dla przykładowego zdania

3.4 Częstotliwość tonu podstawowego F0 (Fundamental Frequency)

Ton podstawowy to najniższy ton dźwięku szeregu harmonicznego, czyli fala harmoniczna o najmniejszej częstotliwości w szeregu harmonicznym. Ton podstawowy w przypadku głosu ludzkiego określa subiektywną wysokość głosu (intonację) i typowo mieści się między 85 a 255 Hz.

Częstotliwość tonu podstawowego można wyliczyć za pomocą funkcji autokorelacji lub AMDF. Funkcja autokorelacji:

$$R_n(l) = \sum_{i=0}^{N-l-1} s_n(i)s_n(i+l) \quad (5)$$


Funkcja AMDF:

$$A_n(l) = \sum_{i=0}^{N-l-1} |s_n(i+l) - s_n(i)| \quad (6)$$

3.5 Eksperymenty związane z parametrami w dziedzinie czasu na poziomie ramki

3.5.1 Detekcja ciszy

Pierwszym etapem eksperymentów było zaimplementowanie algorytmu detekcji ciszy dla plików audio w oparciu o parametr ZCR oraz STE. Na początku został wyznaczony próg dla obu tych wartości w pierwszych 50 ramkach. Ze względu na celowe nakładanie się ramek (co 0.005s) wartość graniczna obliczana jest z pierwszych 0.255s naszego pliku audio. Wartość graniczna została ustawiona jako 5-krotność średniej wartości z pierwszych 50 ramek dla parametru STE oraz ZCR. W przypadku obu parametrów ciszę definiujemy kiedy wartość jest niższa od progowej. Detekcja ciszy dla przykładowego zdania została zobrazowana na rysunku 5




Rysunek 5: Wykres parametru ZCR dla przykładowego zdania

Widoczna cisza, zaznaczona na wykresie pionowymi czerwonymi blokami, w środku zdania podyktowana jest chwilowym zacięciem podczas wypowiedzania słowa. Potwierdza to prawidłowość implementacji zastosowanej metody.


3.5.2 Detekcja fragmentów dźwięcznych/bezdźwięcznych

Eksperyment dźwięczności fragmentów podobnie jak detekcja ciszy polega na odpowiednim określeniu progów parametrów ZCR i STE. Fragmenty dźwięczne to wszystkie samogłoski (a, e, i, o, u) oraz spółgłoski dźwięczne (np. b, d, g, z, w). Fragmenty bezdźwięczne to szelesty, syki i świsty (np. s, sz, f, p, t, k). Wartość graniczna parametru STE pozostaje niezmieniona. Proóg parametru ZCR został sztywno ustawiony na 1500. Ze względu na różnice w przycięciu nagrań, często próg wyliczony z pierwszych ramek był za mały i we fragmentach bezdźwięcznych błędnie pojawiały się przerwy.

Fragmenty dźwięczne w programie zaznaczane są kolorem zielonym, a fragmenty bezdźwięczne niebieskim. Na wykresie 6 przedstawiono wykres ZCR dla słowa "chrząszcz". Na wykresie 6 i 7 dokładnie widać w którym momencie występuje dźwięczna głoska "ą".



Rysunek 6: Wykres ZCR dla słowa "chrząszcz"



Rysunek 7: Przebieg czasowy dla słowa "chrząszcz"

3.5.3 Częstotliwość podstawowa


Implementacja wykrywania częstotliwości podstawowej wymagała wprowadzenia kilku dodatkowych warunków i zmian parametrów. Pierwszym problemem był za mały rozmiar ramki, wynoszący standardowo 10 ms. Ponieważ dolna granica poszukiwanych częstotliwości ludzkiego głosu wynosi 50 Hz, czas trwania jednego pełnego okresu takiej fali to dokładnie 20 ms. Oznaczało to, że w standardowym oknie czasowym nie było fizycznej możliwości zaobserwowania powtarzalności sygnału. Z tego względu na potrzeby wyznaczania częstotliwości podstawowej rozmiar ramki analizy został lokalnie wydłużony do 50 ms.

Kolejnym wyzwaniem było zjawisko naturalnego faworyzowania mniejszych opóźnień przez algorytmy. Wynika to z faktu, że przy większym przesunięciu sygnału (l), liczba nakładających się na siebie próbek maleje. Aby wyniki były wiarygodne dla całego widma częstotliwości, wprowadzono odpowiednią normalizację - w algorytmie AMDF sumę różnic dzielono przez rzeczywistą liczbę zsumowanych elementów, natomiast w autokorelacji ujednolicono górny limit sumowania.


Algorytmy autokorelacji oraz AMDF wykazują również tendencję do błędnego interpretowania szumu oraz głosek bezdźwięcznych jako bardzo wysokich częstotliwości. Aby wyeliminować fałszywe piki na wykresie, wprowadzono próg dźwięczności oparty na całkowitej energii ramki. Wynik uznawano za poprawny tylko wtedy, gdy wartość znalezionej ekstremum stanowiła znaczący procent całkowitej energii sygnału w danym oknie (np. minimum 45%). Dodatkowo wprowadzono mechanizm odrzucania wyników zrównujących się z maksymalną testowaną częstotliwością.

W celu dalszej optymalizacji i zwiększeniu poprawności, analizę F0 ograniczono wyłącznie do ramek zaklasyfikowanych wcześniej jako dźwięczne.

Na wykresie 8 widać, że funkcja AMDF w większości poprawnie określa F0 dla głosu męskiego. Występują jednak anomalie związane z jakością dźwięku i dobraniem parametrów dla których funkcja akceptuje daną częstotliwość jako poprawną. Niestety mimo prób końcowo nie udało się dobrać ich tak, aby były niezawodne w jednej i drugiej metodzie. Dla tego konkretnego pliku funkcja autokorelacji nie wytworzyła nienaturalnych pików, co zostało pokazane na wykresie 9.




Rysunek 8: Wykres F0 dla zdania 1, głos męski, AMDF.




Rysunek 9: Wykres F0 dla zdania 1, głos męski, Autokorelacja.

Na wykresach 10 i 11 ukazano wypowiedzenie tego samego zdania, tym razem przez głos żeński. W tym przypadku oba algorytmy zachowały się podobnie, poprawnie określając F0 dla większości fragmentów, lecz z kilkoma wartościami odstającymi. F0 dla głosu żeńskiego wyszła około 2 razy większa niż dla męskiego, co potwierdza się z powszechną wiedzą. Dodatkowo ten klip posiada przestery, przez które wykresy są bardziej schodkowe.




Rysunek 10: Wykres F0 dla zdania 1, głos żeński, AMDF.



Rysunek 11: Wykres F0 dla zdania 1, głos żeński, Autokorelacja.

Na wykresie 12 przedstawiono F0 dla kolejnych strun gitary w standardowym strojeniu (E (82.41 Hz), A (110 Hz), D (146.83 Hz), G (196 Hz), B (246.94 Hz), E (329.63 Hz)). Dla najniższego dźwięku widać anomalie. Spowodowana jest ona wzmocnieniem drugiej składowej harmonicznej (dokładnie 2 razy częstotliwość podstawowa). Sygnał zdaje się również ucinać przy najwyższej strunie. Jest to spowodowane tym, że cieńsze struny szybciej tracą energię niż grubsze, i fragmenty zaczynają spadać poniżej ustalonego progu energii.



Rysunek 12: Wykres F0 dla kolejnych strun gitary, Autokorelacja.

4 Parametry w dziedzinie czasu na poziomie klipu

W przeciwieństwie do parametrów na poziomie ramki, które opisują krótkie właściwości sygnału w oknach rzędu kilkunastu milisekund, parametry na poziomie klipu definiowane są dla dłuższych jednostek czasu. Klip pomiarowy składa się zazwyczaj z od kilkudziesięciu do kilkuset ramek (często odpowiadając oknom o długości 1–2 sekund). Parametry te nie są obliczane bezpośrednio na podstawie surowych próbek dźwiękowych, lecz stanowią miarę statystyczną (np. wariancję, rozpiętość, entropię) wyliczonych wcześniej cech ramkowych,

takich jak energia (STE) czy współczynnik przejść przez zero (ZCR). Zwracają one pojedynczą wartość dla całego badanego klipu, definiującą dynamikę i charakter sygnału. Pozwalają one z dużą skutecznością odróżnić na przykład ludzką mowę od muzyki, czy szumu tła.

4.1 VDR - Volume Dynamic Range

Parametr ten określa rozpiętość dynamiki głośności w analizowanym klipie. Zdefiniowany jest jako stosunek różnicy między maksymalną a minimalną wartością głośności do głośności maksymalnej w danym oknie czasu. Wzór na VDR przedstawia się następująco:

$$VDR = \frac{v_{max} - v_{min}}{v_{max}} \quad (7)$$

gdzie v_{max} oraz v_{min} oznaczają odpowiednio maksymalną i minimalną głośność wyznaczoną dla ramek w obrębie klipu. Parametr ten jest kluczowy przy rozróżnianiu mowy od muzyki. Mowa ludzka charakteryzuje się naprzemiennym występowaniem głośnych samogłosek i cichych przerw, co skutkuje wysoką wartością VDR. Z kolei muzyka, wykazuje bardzo niskie wartości tego wskaźnika.

4.2 VSTD - Volume Standard Deviation

VSTD czyli znormalizowane odchylenie standardowe głośności to miara statystyczna opisująca, jak bardzo głośność poszczególnych ramek odbiega od średniej głośności klipu. Wyliczone odchylenie normalizowane jest następnie przez głośność maksymalną:

$$VSTD = \frac{\sqrt{\frac{1}{N} \sum_{i=1}^N (v_i - \mu)^2}}{v_{max}}$$

gdzie v_i to głośność i -tej ramki, μ to średnia głośność w klipie, a v_{max} to maksymalna odnotowana głośność. Jest to miara komplementarna do VDR, niezwykle czuła na ciągłe wahania sygnału, osiągająca wartości wysokie dla sygnału mowy.

4.3 VU - Volume Undulation

Falowanie głośności (Volume Undulation) to miara licząca sumę różnic pomiędzy kolejnymi, sąsiadującymi ze sobą lokalnymi ekstremami (szczytami i dolinami) konturu głośności. Równanie można zapisać jako:

$$VU = \frac{1}{N} \sum_{i=2}^K |E_i - E_{i-1}|$$

gdzie E_i to wartość i -tego lokalnego ekstremum (minimum lub maksimum) odnalezionego w konturze głośności, a N to całkowita liczba ramek w klipie (służąca do normalizacji). Podobnie jak VDR, falowanie głośności osiąga wysokie wartości dla mowy.

4.4 LSTER - Low Short-Time Energy Ratio

Współczynnik niskiej energii krótkookresowej określa odsetek ramek w klipie, których energia (STE) spada poniżej 50% średniej energii wyliczonej dla tego samego klipu. Matematycznie parametr ten definiuje się wzorem:

$$LSTER = \frac{1}{2N} \sum_{n=0}^{N-1} [\text{sgn}(0.5 \cdot avSTE - STE(n)) + 1]$$

gdzie N to całkowita liczba ramek w klipie, $STE(n)$ to energia n -tej ramki, a $avSTE$ to uśredniona energia całego klipu. Funkcja signum (sgn) określona jest jako 1 dla wartości dodatnich, -1 dla wartości ujemnych, a 0 dla wartości równej 0. LSTER to niezwykle skuteczna miara w rozróżnianiu mowy i muzyki.

4.5 Energy Entropy

Entropia energii służy do pomiaru miary rozproszenia (chaosu) energii w sygnale. Aby ją obliczyć, energię każdej ramki normalizuje się przez całkowitą energię klipu, a następnie stosuje wzór:

$$I = - \sum_{i=1}^J \sigma_i^2 \log_2(\sigma_i^2)$$

gdzie J to liczba ramek, a σ_i^2 to znormalizowana energia i -tej ramki. Parametr ten idealnie nadaje się do wykrywania scen wybuchowych lub nagłych uderzeń. Dla ciągłej muzyki (gdzie energia rozkłada się równomiernie) entropia przyjmuje wysokie wartości. W przypadku mowy wartość entropii drastycznie maleje.

4.6 HZCRR - High Zero-Crossing Rate Ratio

Współczynnik wysokiej częstotliwości przejść przez zero mierzy odsetek ramek, w których wartość ZCR przekracza 1.5-krotność średniego ZCR dla analizowanego klipu. Wzór wyraża się następująco:

$$HZCRR = \frac{1}{2N} \sum_{n=0}^{N-1} [\text{sgn}(ZCR(n) - 1.5 \cdot avZCR) + 1]$$

Zasada działania opiera się na fizjologii ludzkiej mowy, która przeplata samogłoski ze spółgłoskami bezdźwięcznymi, generującymi potężne, nagłe skoki ZCR. Z tego powodu HZCRR dla mowy jest wysokie, podczas gdy dla muzyki pozostaje na niskim poziomie.

4.7 Eksperymenty związane z parametrami w dziedzinie czasu na poziomie klipu


Zgodnie z opisanymi wcześniej definicjami, przeprowadzono eksperymenty mające na celu automatyczną segmentację nagrania i klasyfikację jego fragmentów jako mowa lub muzyka.

Proces detekcji opiera się na analizie jednosekundowych okien. Algorytm klasyfikuje dany fragment jako mowę wtedy i tylko wtedy, gdy jednocześnie spełnione są trzy warunki progowe:

- **LSTER** > **0.15** – warunek ten wymusza obecność odpowiedniej liczby przerw i gwałtownych spadków energii, które są charakterystyczne dla naturalnych pauz w ludzkiej mowie. Odrzuca on ciągłe, gęste tło muzyczne.
- **HZCRR** > **0.1** – gwarantuje obecność szumowych elementów mowy (takich jak spółgłoski bezdźwięczne i świszczące), co pozwala odróżnić mowę od czystych, harmonicznym tonów instrumentów.
- **VDR** > **0.5** – potwierdza bardzo wysoką rozpiętość dynamiki głośności w badanym oknie. Parametr ten skutecznie odrzuca utwory muzyczne, które na etapie produkcji zostały poddane silnej kompresji.

Niespełnienie wszystkich warunków w analizowanym oknie skutkuje zaklasyfikowaniem go jako muzyki (z tym, że usuwane są przedziały, które zostały wykryte jako cisza). Pozostałe zaimplementowane parametry, takie jak falowanie głośności (VU) oraz entropia energii, posłużyły w fazie eksperymentów do weryfikacji ogólnej charakterystyki sygnału i są eksportowane do pliku z wynikami. Zapisywane są one jako wartości dla całego klipu.

Rezultaty działania tego algorytmu w postaci zaznaczonych segmentów na przebiegu czasowym zaprezentowano na Rysunku 13, gdzie kolorem pomarańczowym są zaznaczone fragmenty muzyki, a fioletowym mowy.



Rysunek 13: Wykres detekcji mowy i muzyki z wyłączeniem fragmentów ciszy dla przykładowego pliku muzycznego

Niestety zauważono problem z niektórymi gatunkami muzyki. Algorytm dla muzyki elektronicznej nie jest w stanie rozróżnić muzyki od mowy, często dając losowe wyniki. Z kolei w przypadku rapu algorytm bardzo dobrze sobie radził. Był w stanie bez problemu wyodrębnić fragmenty śpiewane, oraz muzyczne.